

# Aprendizaje Automático en la clasificación de Sentimientos en Twitter: Comparación de los Algoritmos de LSTM Bidireccional, Regresión Logística y Naïve Bayes

Paula Monge Valverde, Emmanuel Zúñiga Chaves

*Escuela de Ciencias de la Computación e Informática, Universidad de Costa Rica*

*San Pedro de Montes de Oca, Costa Rica*

`mariapaula.monge@ucr.ac.cr`

`emmanuel.zunigachaves@ucr.ac.cr`

## *Abstract—*

### I. INTRODUCCIÓN

El auge de las redes sociales y el uso diario que le dan los usuarios hace de interés analizar qué es lo que se está expresando por medio de estas. Es por eso que surge el análisis de sentimientos en Twitter, que corresponde al estudio por el cual se determina la opinión de los usuarios en redes según la polaridad (positiva, negativa, neutral) sobre un tema en específico, el cual puede abarcar desde productos, películas, política, entre otros [1].

Como se puede ver en el apartado II Trabajos Relacionados, la cantidad de investigaciones alrededor del análisis de sentimientos ha ido en aumento, por ende, existe una enorme variedad de algoritmos que se pueden utilizar para la clasificación de las cargas emocionales asociadas a dichos textos. La aplicación de estos modelos ha dado buenos resultados en un alto porcentaje de los casos, sin embargo, la mayoría de la información proporcionada y de algoritmos creados se basan en un corpus en inglés (tweets escritos en inglés). Cada vez son más los textos que utilizan otros idiomas. Si bien el inglés es la lengua predominante en Internet, hay otros idiomas como el español que cada vez tiene más presencia en las redes sociales, siendo este específicamente el tercer idioma con mayor presencia en la red [2]. Ante esta situación, nos planteamos la siguiente pregunta ¿Cómo será su funcionamiento basado en un corpus de tweets en español?

Es de gran relevancia comprobar cómo se comportan diversos clasificadores a la hora de ser entrenados con un corpus en español, puesto que, además de querer saber que se expresa en este idioma es importante medir su exactitud de clasificación cuando se cambia de

lenguaje ya que se ha evidenciado que algoritmos como **Máquinas de Soporte Vectorial (SVM)** proporcionan resultados fiables en textos en inglés, mientras que en textos en español el máximo nivel de exactitud (cantidad de clasificaciones correctas) apenas supera el 72%. Se trata de una cifra que todavía no resulta aceptable para la investigación [3].

Este artículo explora y evidencia los distintos algoritmos ampliamente utilizados para el análisis de sentimientos en Twitter basados en un corpus en español, con el fin de exponer cuáles de ellos tienen un mejor rendimiento, tomando en cuenta las diversas métricas de clasificación, las cuales se explicarán más adelante en el artículo. El funcionamiento de dichos algoritmos, se centra en la clasificación de los sentimientos, a partir de un análisis de las características sintácticas y semánticas del texto en cuestión [4]. Los algoritmos seleccionados para el desarrollo del análisis serán **LSTM Bidireccional, Regresión Logística y Naïve Bayes**. La razón de dicha selección, recae en el amplio uso que se les da en dicha área, es así como surge la necesidad de identificar el algoritmo óptimo para la clasificación de tweets en español.

### II. TRABAJOS RELACIONADOS

Internet es un amplio entorno en el cual se puede recopilar una gran cantidad de información [5], la cual enriquece la capacidad de análisis de diferentes patrones de comportamiento, opinión y sentimientos de los usuarios en diferentes plataformas. A consecuencia de esto surgen distintas alternativas en cuanto a opciones para la clasificación de sentimientos en tweets, por lo tanto, gran parte de los trabajos relacionados se enfocan en ofrecer un

análisis sobre los resultados obtenidos al aplicar dichas técnicas.

En su trabajo teórico el autor H. Khandewal [6], realiza una explicación sobre cómo el algoritmo de **Naïve Bayes** puede ser implementado para clasificar los sentimientos expresados en los tweets. Según Khandewal, Naïve Bayes permite determinar la contribución de cada palabra al sentimiento asociado, y calcular la relación entre la probabilidad de aparición de una palabra y las etiquetas asociadas a la clasificación. Similarmente, Ulfa, Irmawati y Husudo [7] efectúan una implementación del modelo basado en **Naïve Bayes**. Para ello realizan la experimentación con y sin la selección de características de información mutua (MI) para escoger las más relevantes dentro del conjunto de datos de tweets, obteniendo resultados de accuracy de entre el 96.2% y el 97.9% en el experimento implementado con MI.

Por otro lado, otras investigaciones se centran más en hacer un análisis del corpus dado un contexto. Chiorrini, Diamantini, Mircoli y Potena [8] realizan una implementación de un modelo de clasificación basado en **BERT**. Para ello, se recurrió a un conjunto de datos con más de un millón de tweets, clasificados según el sentimiento (positivo, negativo, neutral), obteniendo un accuracy del 92%, del cual se deduce que los modelos del lenguaje de **BERT** contribuyen a la obtención de buenos resultados en la clasificación de textos.

### III. METODOLOGÍA

La selección de los algoritmos se basa en el amplio uso que se les da en el ámbito de clasificación de sentimientos, sin embargo, es de importancia aclarar que en un inicio uno de los algoritmos seleccionado fue “**BERT**”, que como se mencionó anteriormente, obtenía buenos resultados de clasificación, no obstante, a la hora de realizar la experimentación con el dataset seleccionado se noto que el entrenamiento de dicho algoritmo tomaba mucho tiempo, lo cual no era conveniente para la investigación, por lo que se tomó la decisión de usar como reemplazo el algoritmo de Regresión Logística, el cual sirve para resolver problemas de clasificación binaria [9], esto se adapta a nuestro objetivo que busca clasificar los tweets en una polaridad positiva y negativa

Cuando se quiere evaluar el rendimiento de un *programa de clasificación* se suelen usar las métricas de precision, recall, F1-Score y accuracy. Cada una de ellas aporta distintos datos que permiten analizar el funcionamiento de la clasificación; **precision** indica el porcentaje de todas las predicciones positivas cuáles de ellas son correctas, **recall** indica el porcentaje de todos los

positivos cuáles son reales (TP), **F1-Score** se trata de una mezcla de las dos métricas mencionadas anteriormente, haciéndolas funcionar de manera armónica/equilibrada y también **accuracy**, que nos brinda el porcentaje de casos que el modelo ha acertado, es decir, nos indica que tan exacta fue la clasificación de los datos. Si bien esta métrica es conocida por ser “engañosa”, esta característica se da cuando se poseen datos con clases desbalanceadas. Con el fin de evaluar el desempeño de los algoritmos, se tomarán en cuenta las cuatro métricas mencionadas anteriormente.

Para efectos de investigación se utiliza un dataset con más de 170 mil registros en español, clasificados en positivos y negativos. No obstante, el conjunto de datos en cuestión posee más cantidad de tweets clasificados como negativos. Por lo tanto, se aplicó una reducción de la cantidad de datos en la clase con mayor frecuencia para así obtener un conjunto de datos más balanceado. Obteniendo así, la misma cantidad de datos para ambas clases, y en consecuencia se disminuye la cantidad de datos a aproximadamente 111 mil registros.

Respecto al preprocesamiento de datos, se aplica una limpieza de los textos. En este proceso se eliminan emojis, caracteres especiales y stopwords. Por otro lado, también se eliminan valores nulos, valores repetidos, y otros elementos en los datos que podrían afectar al rendimiento de la clasificación. Con los datos debidamente preprocesados, se procede a la creación de conjuntos de entrenamiento y prueba, para lo cual se utiliza una proporción del 80:20, si bien, existen otros métodos de división de conjuntos más sofisticadas, 80:20 suele ser suficiente para modelos de aprendizaje automático [10].

Una vez creados los conjuntos, se procede al entrenamiento y ajuste de los modelos seleccionados, para ello se recurre a la combinación de diferentes hiperparámetros y posteriormente, la evaluación de los resultados de clasificación, lo cual será analizado en el apartado IV Análisis de resultados.

### IV. ANÁLISIS DE RESULTADOS

### V. DISCUSIONES Y CONCLUSIONES

### REFERENCIAS

- [1] L. Montesinos García, “Análisis de Sentimientos y Predicción de Eventos en Twitter,” Memoria para optar al título de Ingeniero Civil Eléctrico, Universidad de Chile, Santiago de Chile, 2014. [https://repositorio.uchile.cl/bitstream/handle/2250/130479/cf-montesinos\\_lg.pdf](https://repositorio.uchile.cl/bitstream/handle/2250/130479/cf-montesinos_lg.pdf)
- [2] Instituto Cervantes, “Anuario 2019. El español en internet y en las redes sociales,” CVC, 2019.

[https://cvc.cervantes.es/lengua/anuario/anuario\\_19/informes\\_ic/p04.htm](https://cvc.cervantes.es/lengua/anuario/anuario_19/informes_ic/p04.htm)

[3] T. Baviera, "Técnicas para el análisis del sentimiento en Twitter: Aprendizaje Automático Supervisado y SentiStrength", *Dígitos*, pp. (38-40), Dic, 2017

[4] P. Mollah, "An LSTM model for Twitter Sentiment Analysis", 2022, <https://arxiv.org/abs/2212.01791>

[5] ON. A. Awad and A. Mahmoud, "Analyzing customer reviews on social media via applying association rule," *Computers, Materials and Continua*, vol. 68, no. 2, pp. 1519–1530, Apr. 2021, doi: 10.32604/CMC.2021.016974.

[6] H. Khandewal. "Sentiment Analysis of a Tweet With Naive Bayes". Medium. <https://towardsdatascience.com/sentiment-analysis-of-a-tweet-with-naive-bayes-ff9bdb2949c7>

[7] M. A. Ulfa, B. Irmawati, and A. Y. Husodo, "Twitter Sentiment Analysis using Naive Bayes Classifier with Mutual Information Feature Selection," *J. Comput. Sci. Inform. Eng. (J-Cosine)*, vol. 2, no. 2, pp. 106-111, Dec. 2018, doi: <https://doi.org/10.29303/jcosine.v2i2.120>

[8] A. Chiorrini, C. Diamantini, A. Mircoli, and D. Potena, "Emotion and sentiment analysis of tweets using BERT," in *Proceedings of the EDBT/ICDT Workshops*, Nicosia, Cyprus, Mar. 23-26, 2021.

[9] "Análisis de sentimiento con regresión logística," ICHI.PRO. <https://ichi.pro/es/analisis-de-sentimiento-con-regresion-logistica-173659997957551> (accessed May 12, 2023).

[10] "Aprendizaje automático y datos de entrenamiento: lo que debes saber," Ciberseguridad. <https://ciberseguridad.com/guias/nuevas-tecnologias/machine-learning/datos-entrenamiento/> (accessed May 12, 2023).